

Rappel : Famille Γ : $Q_{\theta} = \{Q(\cdot | \theta) \mid \theta \in \Theta\}$

$$Q(\cdot | \theta) = \int_0^{\infty} t^{\theta-1} \frac{\theta^t}{\Gamma(\theta)} e^{-\theta t} dt$$

$$\theta = \{\theta \mid \theta > 0\}$$

Ex G.7.4 $Q(\cdot | (x_1, \dots, x_n))$ à la densité $q(\cdot | (x_1, \dots, x_n))$ donnée par

$$\forall \lambda > 0, q(\lambda | (x_1, \dots, x_n)) = \frac{L_n(x_1, \dots, x_n, \lambda)}{\int_{\lambda > 0} L_n(x_1, \dots, x_n, \lambda) q(\lambda) d\lambda} q(\lambda)$$

$$\int_{\lambda > 0} L_n(x_1, \dots, x_n, \lambda) q(\lambda) d\lambda$$

G : VASCI

$$\ln(Q_{\text{Gamma}}(\cdot, \lambda)) = \prod_{k=1}^n \ln(q(x_k, \lambda))$$

$$= \prod_{k=1}^n e^{-\lambda} \frac{x_k}{x_k!}$$

$$\begin{aligned} \text{D'où } q(\lambda | (x_1, \dots, x_n)) &\propto e^{-n\lambda} \frac{\lambda^{\sum x_k}}{\prod_{k=1}^n x_k!} \times \frac{\theta^0}{\Gamma(\theta)} \lambda^{\theta-1} e^{-\theta\lambda} \\ &= \frac{1}{\prod_{k=1}^n x_k!} \times \frac{\lambda^{\sum x_k + \theta - 1}}{\Gamma(\theta)} \times e^{-\lambda(\theta+n)} \theta^\theta \\ &\propto \frac{\lambda^{\sum x_k + \theta - 1}}{e^{-\lambda(\theta+n)}} \end{aligned}$$

Mai : $Q(\cdot | (x_1, \dots, x_n)) = \prod \left(\sum_{k=1}^n x_k + \theta, \theta + n \right)$

Conclusion : la loi a posteriori est dans Q donc Q est conforme pour le modèle θ .

Ex G.A.3 Rappel : Si $X \sim \Gamma(a, \lambda)$, $E(X) = \frac{a}{\lambda}$ et $V(X) = \frac{a}{\lambda^2}$.

Q+1

• Moyenne a posteriori

On a $\mathbb{E}(x_1, \dots, x_n) \in \mathbb{N}^n$,

$$\theta_n^{\text{PM}}(x_1, \dots, x_n) = \int_{\theta > 0} \theta Q_{\text{Gamma}}(\theta | (x_1, \dots, x_n))$$

G : Par l'exo précédent on sait que :

$$Q_{\text{Gamma}}(\cdot | (x_1, \dots, x_n)) = \prod \left(\sum_{k=1}^n x_k + a, \lambda + n \right)$$

D'où $\theta_n^{\text{PM}}(x_1, \dots, x_n) = E(X)$ où $X \sim \Gamma\left(\sum_{k=1}^n x_k + a, \lambda + n\right)$

$$\theta_n^{\text{PM}}(x_1, \dots, x_n) = \frac{a + \sum_{k=1}^n x_k}{\lambda + n}$$

1

Où : $\hat{\theta}_n^{\text{PM}} = \frac{a + \sum_{k=1}^n x_k}{n + \lambda}$

- Maximum a posteriori

$$q(\theta | (x_1, \dots, x_n)) \propto \theta^{\sum_{k=1}^n x_k + a - \lambda} e^{-(\lambda + n)\theta}$$

$$= e^{(\sum_{k=1}^n x_k + a - \lambda) \ln(\theta) - (\lambda + n)\theta}$$

Il suffit de maximiser $f: \Theta \ni \left(\sum_{k=1}^n x_k + a - \lambda \right) \ln(\theta) - (\lambda + n)\theta$

→ On impose $a > y$, de sorte que f atteint son max en un unique point $\hat{\theta}_n^{\text{MAP}}(x_1, \dots, x_n) = \frac{\sum_{k=1}^n x_k + a - \lambda}{n + \lambda}$

Donc : $\hat{\theta}_n^{\text{MAP}} = \frac{\sum_{k=1}^n x_k + a - \lambda}{n + \lambda}$

$\hat{\theta}_n^{\text{PM}} = \frac{n \left(\frac{a}{n} + \bar{x}_n \right)}{n + \lambda}$

Or : $\bar{x}_n \xrightarrow{\text{PS}} E(x_1) = \theta$ par la loi forte.

Donc $\hat{\theta}_n^{\text{PM}} \xrightarrow{\text{PS}} \theta$ et $\hat{\theta}_n^{\text{PM}}$ est fortement consistant.

De la même façon,

$$\hat{\theta}_n^{\text{MAP}} = \frac{n \left(\frac{a-1}{n} + \bar{x}_n \right)}{n+1} \xrightarrow{\text{PS}} \theta \quad \text{car } \bar{x}_n \xrightarrow{\text{PS}} \theta \text{ par la loi forte}$$

Donc $\hat{\theta}_n^{\text{MAP}}$ est fortement cons.

3) Dès que $\hat{\theta}_n^{\text{PM}}$ est fortement consistant.

De plus : $\forall (x_1, \dots, x_n) \in \mathbb{N}^n$, on a

$$V_n(x_1, \dots, x_n) = \int_{\theta \geq 0} (\theta - \hat{\theta}_n^{\text{PM}})^2 Q(d\theta | (x_1, \dots, x_n))$$

$$= V(x) \text{ où } X \sim \Gamma\left(\sum_{k=1}^n x_k + a, \lambda + n\right)$$

$$= \frac{\sum_{k=1}^n x_k + a}{(\lambda + n)^2}$$

$$\text{D'où : } V_n(x_1, \dots, x_n) = \frac{\sum_{k=1}^n x_k + a}{(x+n)^2}$$

$$V_n(x_1, \dots, x_n) = \frac{n}{(x+n)^2} \left(\overbrace{x_n + \frac{a}{n}}^{\xrightarrow[n]{\text{P.S.}} 0} \right) \xrightarrow[n]{\text{P.S.}} 0$$

par la suite

Bilan : Sur le coup, l'estimation bayésienne de θ avec la loi a priori $Q(\theta)$ est constante.

Ex.G.A.h.1 Si (x_1, \dots, x_n) viennent de $\mathcal{N}(\mu, \sigma^2)$,

$$Q(\mu_i | (x_1, \dots, x_n)) = \frac{L_n(x_1, \dots, x_n; \mu_i) Q(\mu_i)}{\sum_{j=1}^n L_n(x_1, \dots, x_n; \mu_j) Q(\mu_j)}$$

Or, VieCf.k.1,

$$L_n(x_1, \dots, x_n; \mu_i) = \prod_{e=1}^n p(x_e; \mu_i)$$

et $x_e \sim \mathcal{N}(\mu_i, \sigma^2)$. Donc :

$$\begin{aligned} L_n(x_1, \dots, x_n; \mu_i) &= \prod_{e=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} e^{\frac{(x_e - \mu_i)^2}{2\sigma^2}} \\ &= \frac{1}{(2\pi\sigma^2)^n} e^{-\frac{1}{2\sigma^2} \sum_{e=1}^n (x_e - \mu_i)^2}. \end{aligned}$$

Donc :

$$Q(\mu_i | (x_1, \dots, x_n)) = \frac{\frac{1}{(2\pi\sigma^2)^n} e^{-\frac{1}{2\sigma^2} \sum_{e=1}^n (x_e - \mu_i)^2} Q(\mu_i)}{\sum_{j=1}^n \frac{1}{(2\pi\sigma^2)^n} e^{-\frac{1}{2\sigma^2} \sum_{e=1}^n (x_e - \mu_j)^2} Q(\mu_j)}$$

$$Q(\mu_i | (x_1, \dots, x_n)) = \frac{e^{-\frac{1}{2\sigma^2} \sum_{e=1}^n (x_e - \mu_i)^2} Q(\mu_i)}{\sum_{j=1}^n e^{-\frac{1}{2\sigma^2} \sum_{e=1}^n (x_e - \mu_j)^2} Q(\mu_j)}$$

c)

On rappelle que : $\forall i \in \{1, k\}$,

$$Q(\mu_i | (x_1, \dots, x_n)) = \frac{Q(\mu_i)}{\sum_{j=1}^k e^{-\frac{n}{2\sigma^2} U_{ij}} Q(\mu_j)}$$

Or : pour tout $j \in \{1, k\}$, $\sum_{i=1}^n U_{ij} \xrightarrow{n \rightarrow \infty} (\mu_i - \mu_j)^2$

et donc : $\forall j \neq i \in \{1, k\}$, on obtient

$$\left| \sum_{i=1}^n U_{ij} \xrightarrow{n \rightarrow \infty} 0 \right| \text{ car } (\mu_i - \mu_j)^2 > 0$$

et donc $\frac{1}{\sum_{i=1}^n U_{ij}} \xrightarrow{n \rightarrow \infty} 0$

Oras que $\forall n \in \mathbb{N}$,

$$\left| \sum_{i=1}^n U_{ii} = \sum_{i=1}^n \frac{(\mu_i - p_s)^2}{\sigma^2} \right| \quad (U_{ii} = c)$$

ctiss, il vient :

$$\left| Q(\mu_i | (x_1, \dots, x_n)) \xrightarrow{n \rightarrow \infty} \frac{Q(\mu_i)}{Q(\mu_i)} = 1 \right|$$

i.e. l'estimation bayesienne de μ_i est consistante.

3)

. On visualise la consistance de l'estimation bayesienne en remarquant que lorsque n est grand, la loi a posteriori s'approche d'une indicatrice en le point μ qui correspond au bruit qui a émis le signal.

. Plus k est grand, moins on a besoin que n soit grand pour retrouver la valeur de μ .

21

Q21 a) On écrit : $\forall i \in \{1, \dots, k\},$

$$Q(\mu_i | (x_1, \dots, x_n)) = \frac{Q(\mu_i)}{\sum_{j=1}^k e^{-\frac{1}{2\sigma^2} \sum_{e=1}^n [(x_e - \mu_j)^2 - (x_e - \mu_i)^2]} Q(\mu_j)}$$

$$Q(\mu_i | (x_1, \dots, x_n)) = \frac{Q(\mu_i)}{\sum_{j=1}^k e^{-\frac{n}{2\sigma^2} U_{ij}} Q(\mu_j)}$$

b) On écrit :

$$U_{ij} = \frac{1}{n} \sum_{e=1}^n y_e \text{ avec } y_e = (x_e - \mu_j)^2 - (x_e - \mu_i)^2.$$

Les y_e sont iid et L^2 , si bien que pour par la forte,
on a $\sum_{ij}^n \frac{P_{\mu_i - \mu_j}}{n\sigma^2} \xrightarrow{\text{Théorème}}$

On calcule :

$$\mathbb{E}_{\mu_i}(Y_{ij}) = \mathbb{E}_{\mu_i}((x_i - \mu_j)^2) - \mathbb{V}_{\mu_i}(x_i)$$

On a :

$$(x_i - \mu_j)^2 = ((x_i - \mu_i) + (\mu_i - \mu_j))^2 \\ = (x_i - \mu_i)^2 + (\mu_i - \mu_j)^2 + 2(x_i - \mu_i)(\mu_i - \mu_j)$$

$$\text{Donc } \mathbb{E}_{\mu_i}(x_i - \mu_j)^2 = \mathbb{V}_{\mu_i}(x_i) + (\mu_i - \mu_j)^2$$

et enfin

$$\mathbb{E}_{\mu_i}(Y_{ij}) = (\mu_i - \mu_j)^2$$

$$\text{D'où : } \boxed{\sum_{ij}^n \frac{P_{\mu_i - \mu_j}}{n\sigma^2} (\mu_i - \mu_j)^2}$$

Gamma Prior Distributions



